inteli EXEC

BEM-VINDOS!
PROGRAMA
AI FOR BUSINESS

Wifi
Inteli - Visitantes

inteli EXEC



rmnicola.github.io/inteli-exec/essencial-na-pratica



QUEM CONDUZ

Rodrigo Nicola

Professor · Inteli

- Engenheiro mecatrônico (Mauá), mestre pelo ITA
- Veículos autônomos e aprendizado de máquina
- No Inteli desde 2022

Rodrigo Mangoni Nicola

inteli EXEC

AGENDA

9h15	**Bloco 1 · de Turing ao modelo de linguagem**
9h55	Bloco 2 · janela e camadas de contexto
10h35	Break
10h50	Bloco 3 · entendendo os agentes
11h50	Escolha do problema
12h20	Almoço
13h20	Construção em duplas
14h50	Apresentações
15h45	Fechamento

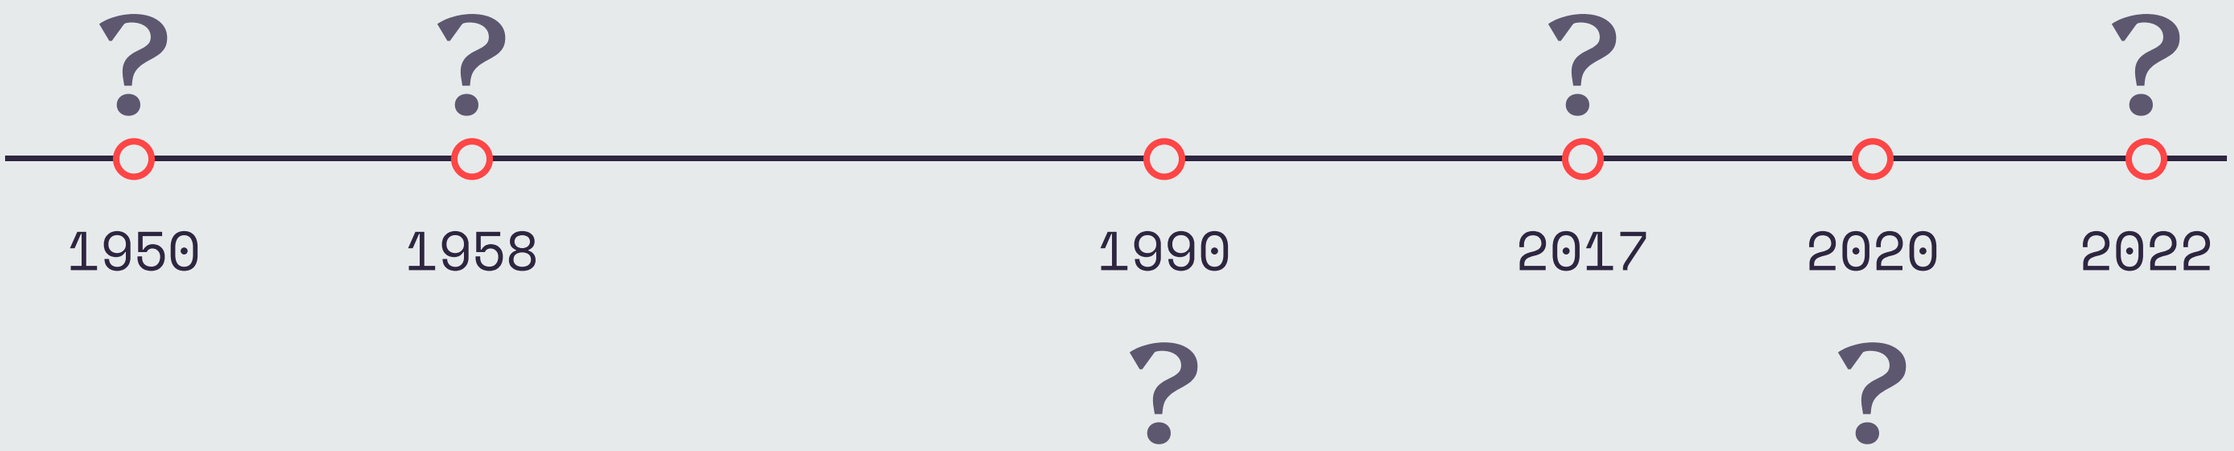
LEARNING LOG



1. Desmistificando a IA

Enquanto a conversa acontece, anote só as palavras-chave. A definição vem depois, com os colegas.

	Palavra-chave	O que é, nas minhas palavras
1		
2		
3		
4		
5		
6		
7		
8		
9		
10		


?
?
?
?
1950
1958
1990
2017
2020
2022
?
?

VOL. LIX. No. 236.] [October, 1950

MIND

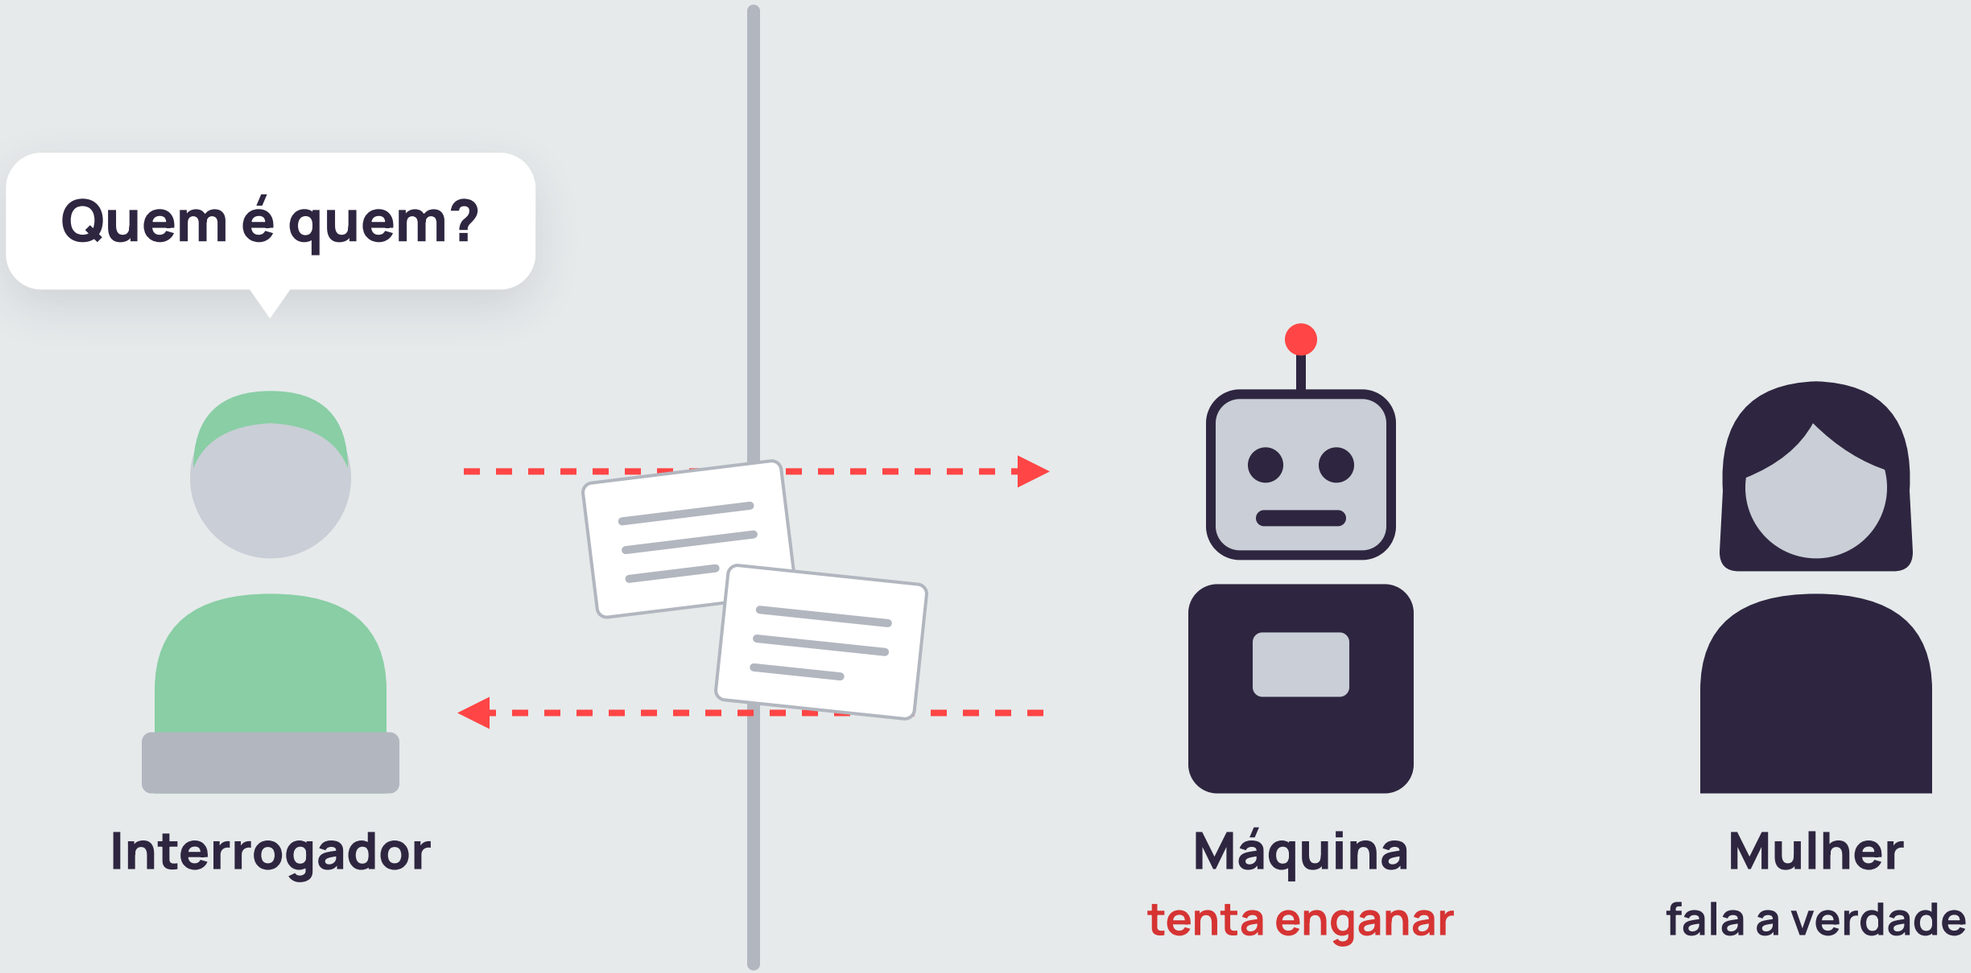
A QUARTERLY REVIEW OF PSYCHOLOGY AND PHILOSOPHY

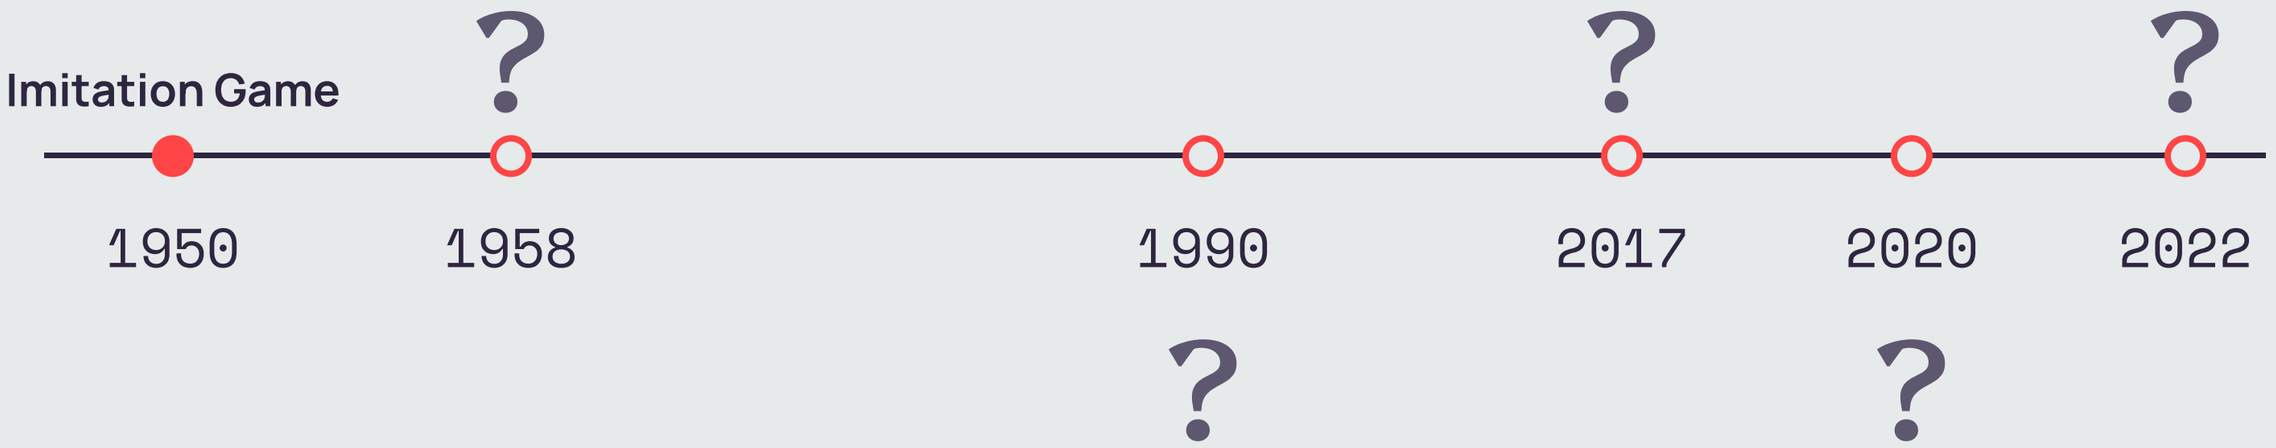
I.—COMPUTING MACHINERY AND INTELLIGENCE

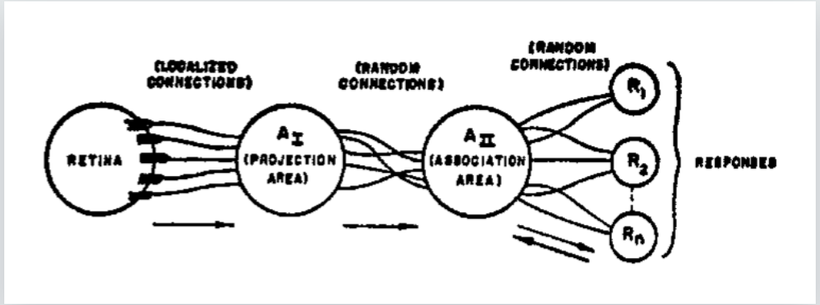
BY A. M. TURING

1. The Imitation Game.

I PROPOSE to consider the question, 'Can machines think?'


Quem é quem?
Interrogador
Máquina
tenta enganar
Mulher
fala a verdade


Imitation Game
?
?
?
1950
1958
1990
2017
2020
2022
?
?



Entradas
RETINA

Pesos
CONEXÕES

x_1 x_2 x_3 x_4

w_1 w_2 w_3 w_4

Soma
ASSOCIAÇÃO

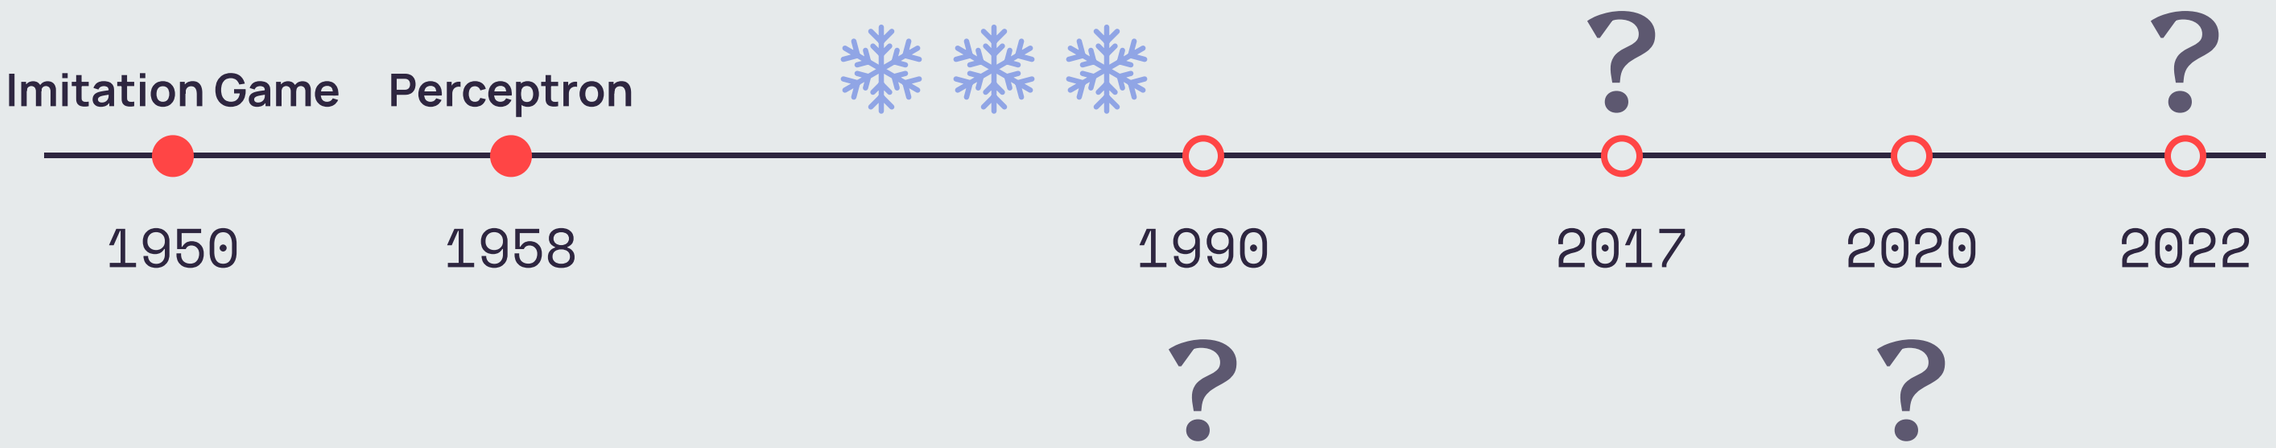
Σ

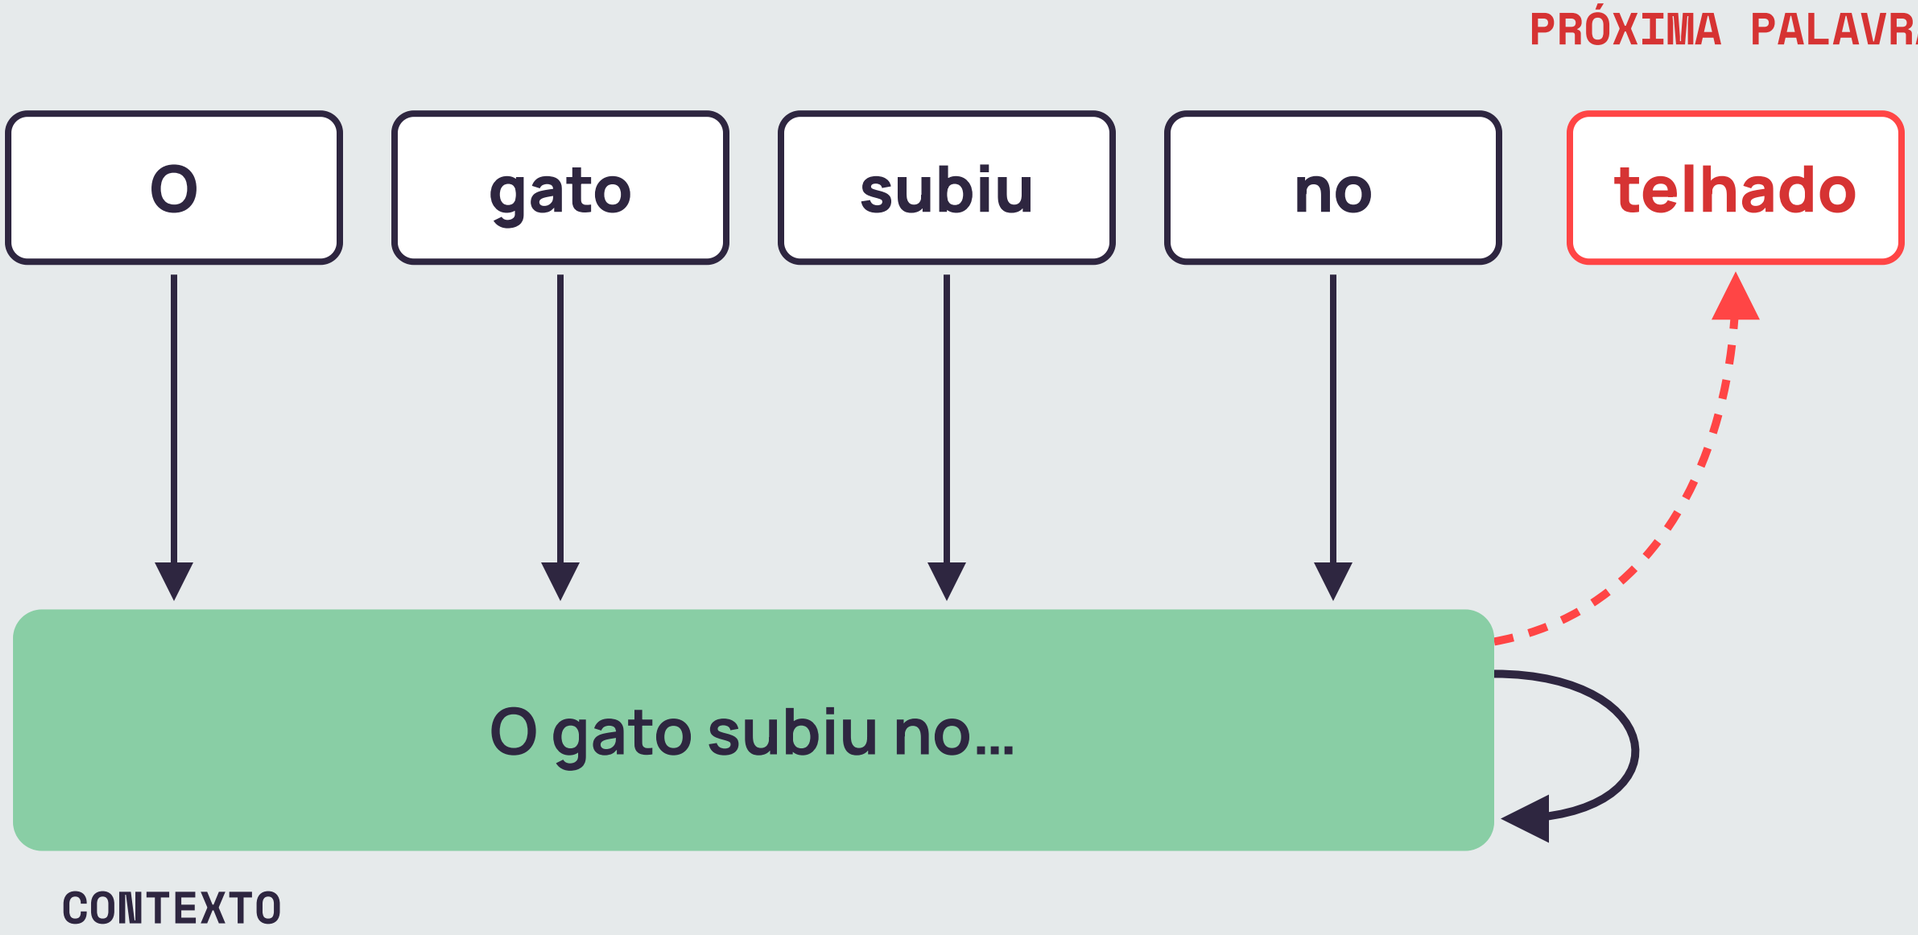
Limiar

Saída
RESPOSTA

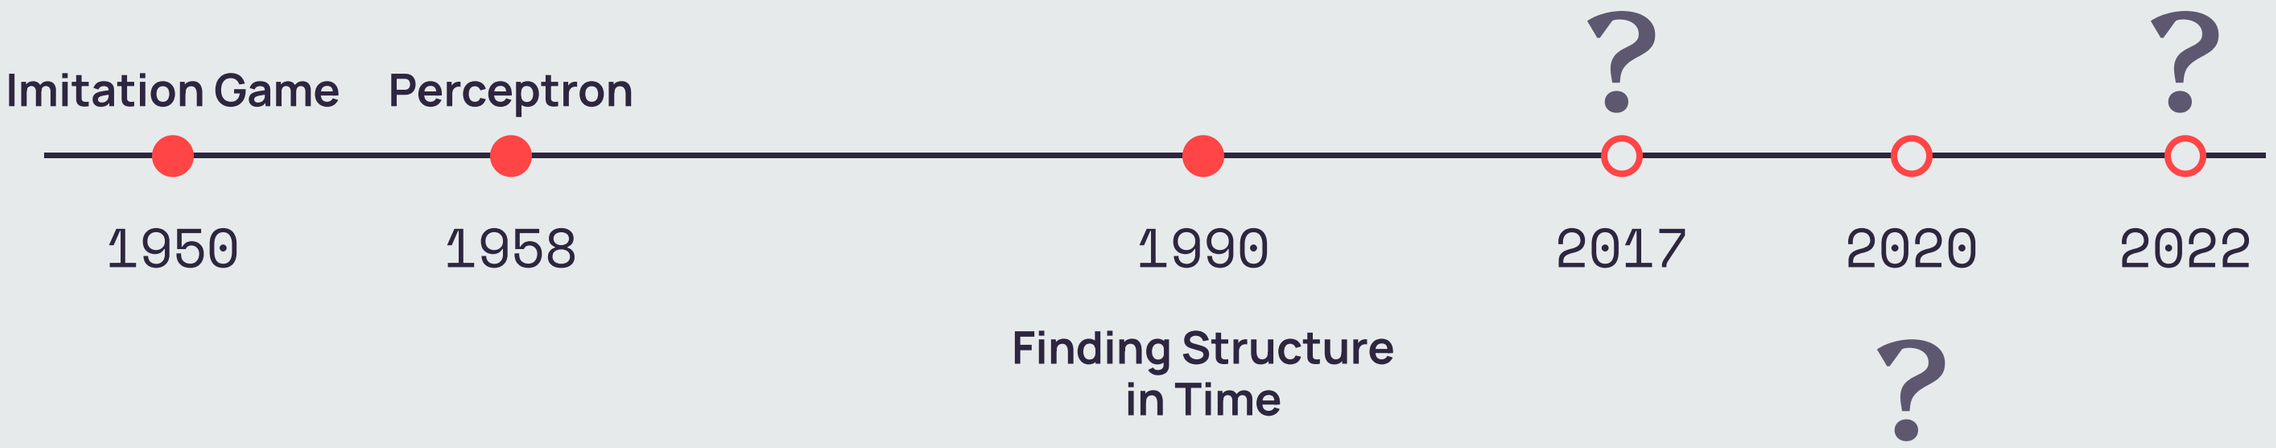
1 | 0

errou? ajusta os pesos

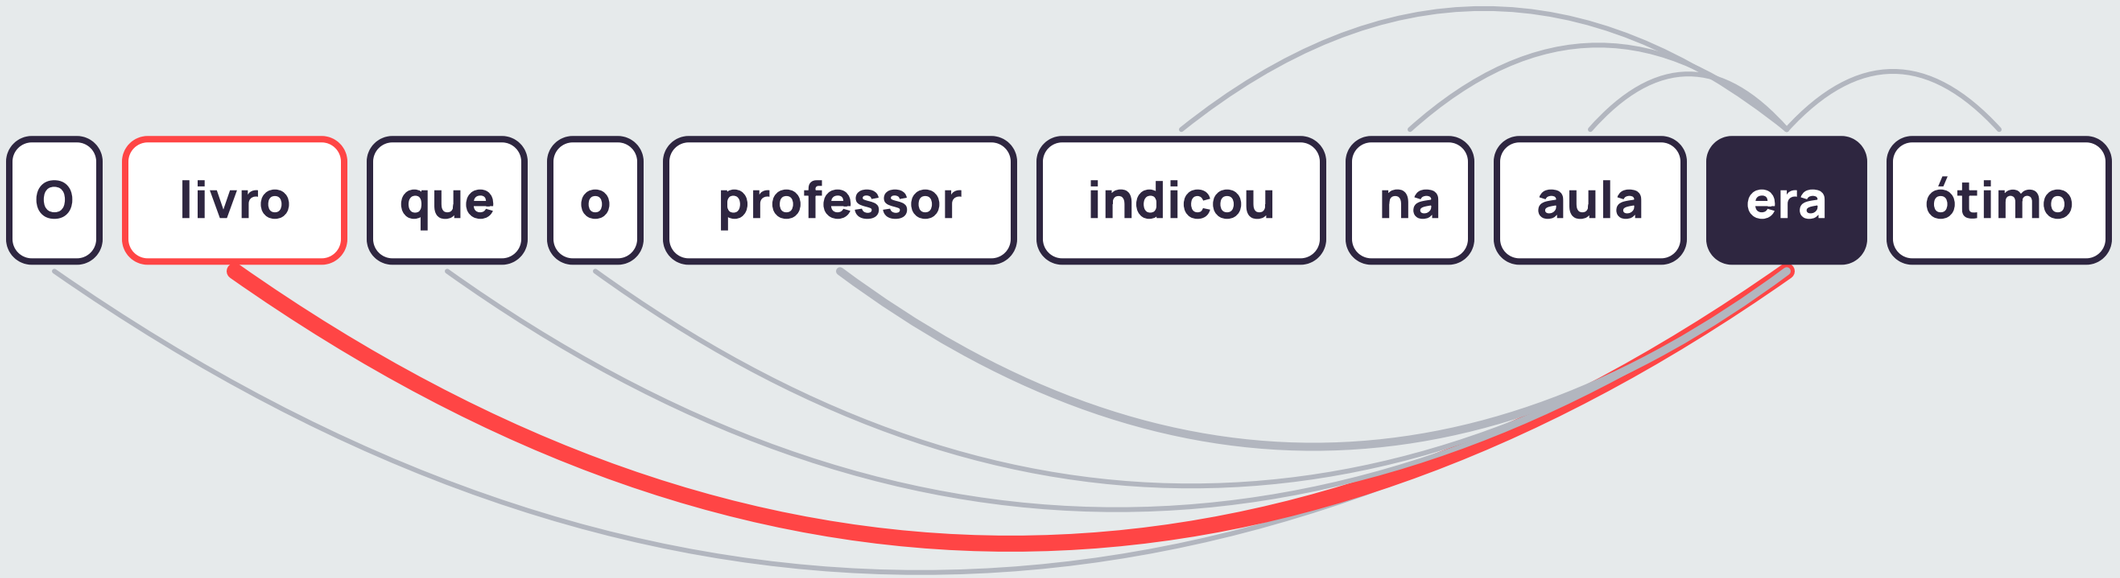

Imitation Game
Perceptron
1950
1958
1990
2017
2020
2022
?
?
?
?



Elman (1990), *Finding Structure in Time*


Imitation Game
Perceptron
?
?
1950
1958
1990
2017
2020
2022
Finding Structure
in Time
?

ATENÇÃO



Vaswani et al. (2017), *Attention Is All You Need*

inteli EXEC

O gato subiu no telhado

O | g | ato | sub | iu | no | tel | h | ado

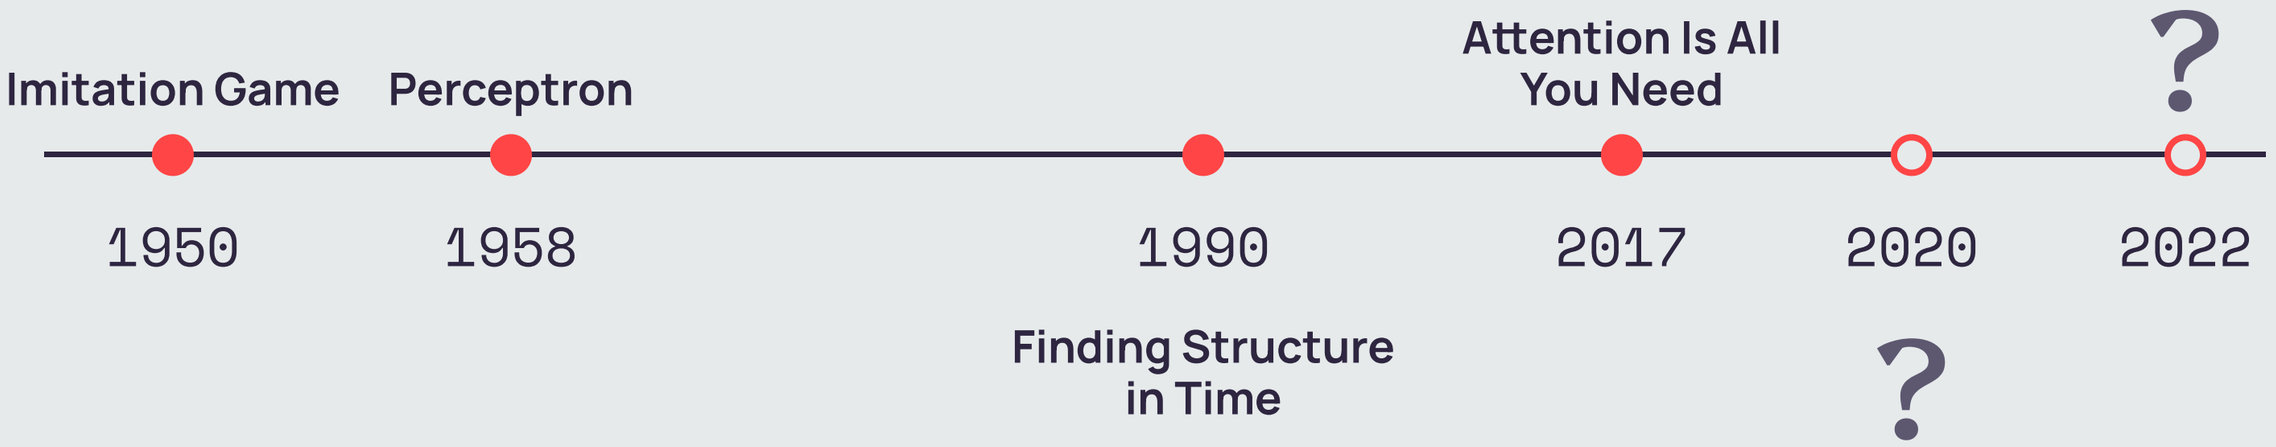
9 TOKENS GPT-3 GPT-4o

The | cat | climbed | onto | the | roof

6 TOKENS

Quantos r tem strawberry?

st | raw | berry


Imitation Game
Perceptron
Attention Is All You Need
?
1950
1958
1990
2017
2020
2022
Finding Structure in Time
?

arXiv:2005.14165 [cs.CL] 28 May 2020

Language Models are Few-Shot Learners

Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal
Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss
Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu
Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray
Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever
Dario Amodei

OpenAI

Abstract

Recent work has demonstrated substantial gains on many NLP tasks and benchmarks by pre-training on a large corpus of text followed by fine-tuning on a specific task. While typically task-agnostic in architecture, this method still requires task-specific fine-tuning datasets of thousands or tens of thousands of examples. By contrast, humans can generally perform a new language task from only a few examples or from simple instructions – something which current NLP systems still largely struggle to do. Here we show that scaling up language models greatly improves task-agnostic, few-shot performance, sometimes even reaching competitiveness with prior state-of-the-art fine-tuning approaches. Specifically, we train GPT-3, an autoregressive language model with 175 billion parameters, 10x more than any previous non-sparse language model, and test its performance in the few-shot setting. For all

PROMPT

```
1  queijo =>
```

← *prompt*

MODELO

Queijo é um alimento feito a partir do leite coalhado. Existem centenas de tipos, como o minas, o parmesão e o gorgonzola.

ZERO-SHOT

```
1  Traduza do português para o inglês:

2  queijo => .....
```

← *descrição da tarefa*

← *prompt*

MODELO

Queijo, em inglês, é “cheese”.

ONE-SHOT

```
1  Traduza do português para o inglês:
2  lontra-marinha => sea otter
3  queijo => .....
```

← *descrição da tarefa*

← *exemplo*

← *prompt*

MODELO

cheese

FEW-SHOT

```
1  Traduza do português para o inglês:
2  lontra-marinha => sea otter
3  hortelã-pimenta => peppermint
4  girafa de pelúcia => plush giraffe
5  queijo =>
```

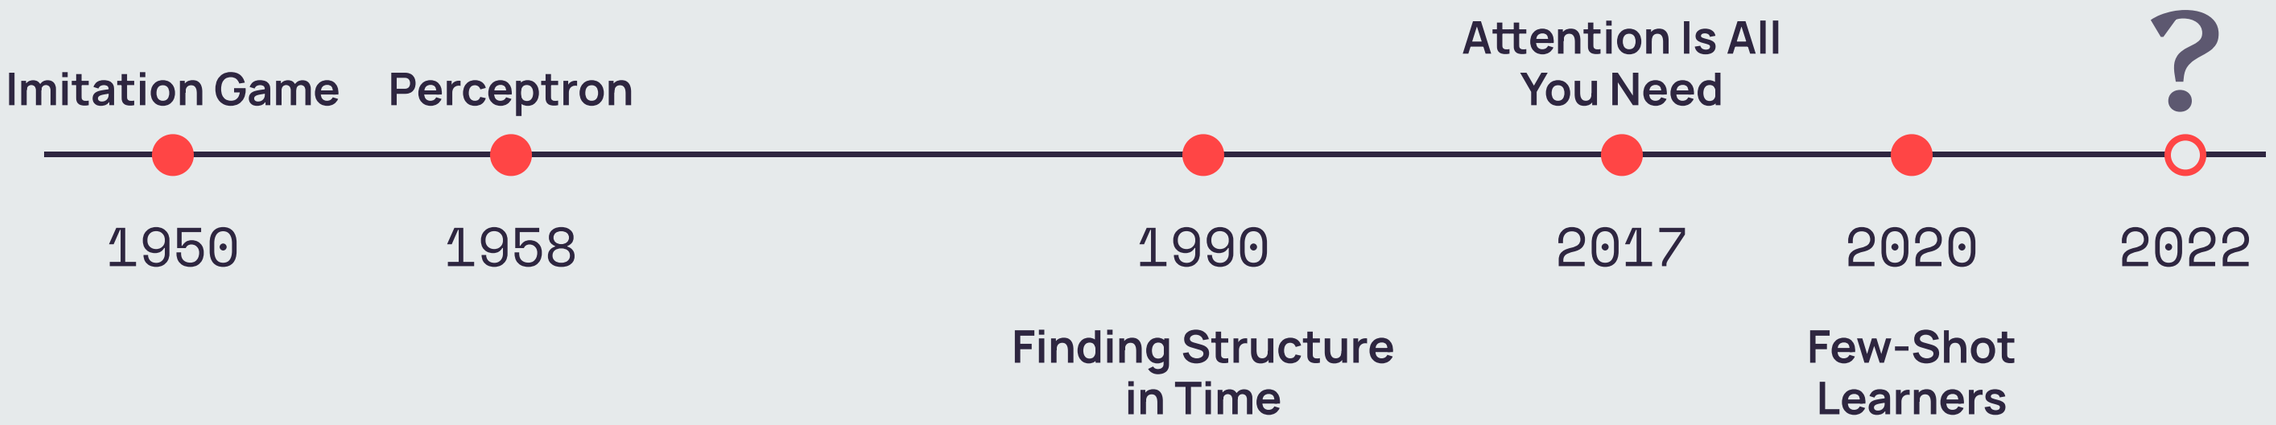
← *descrição da tarefa*

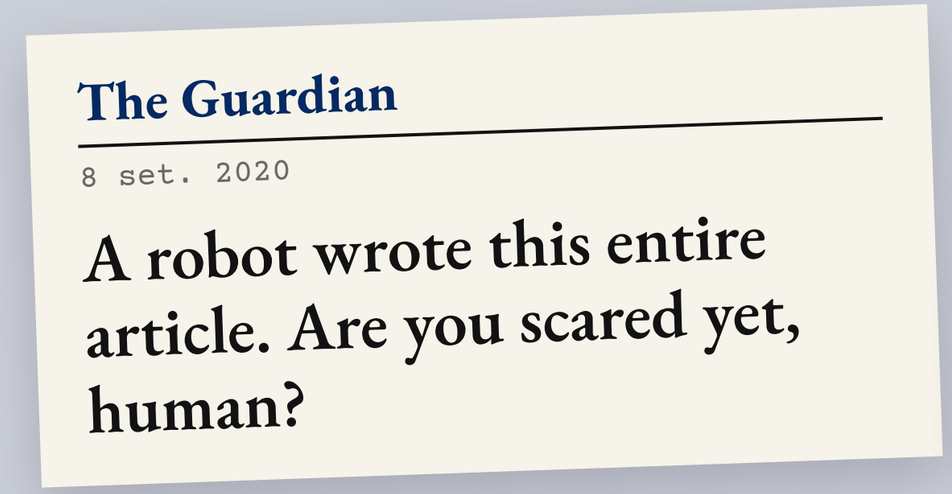
← *exemplos*

← *prompt*

MODELO

cheese


Imitation Game
Perceptron
Attention Is All You Need
?
1950
1958
1990
2017
2020
2022
Finding Structure in Time
Few-Shot Learners


The Guardian
8 set. 2020
A robot wrote this entire article. Are you scared yet, human?


REUTERS
1 fev. 2023
ChatGPT sets record for fastest-growing user base


TIME
27 fev. 2023
The AI Arms Race Is Changing Everything


CNN Brasil
29 mar. 2023
Inteligência artificial pode afetar 300 milhões de empregos no mundo, diz Goldman Sachs


The New York Times
21 dez. 2022
A New Chat Bot Is a ‘Code Red’ for Google’s Search Business


Forbes
30 mai. 2023
Nvidia Hits $1 Trillion Market Value

inteli EXEC

PROMPT

Papel
quem o modelo deve ser

Tarefa
o que fazer

Formato
como entregar

Exemplos
como deve ficar

QUEM VAMOS AJUDAR?

- H Helena
- D Diego
- **B Beatriz**

ARQUITETA AUTÔNOMA

Beatriz

A DOR

“Passo a noite respondendo cliente, e as respostas são sempre parecidas.”

O QUE JÁ EXISTE

- tabela de serviços e preços
- oito respostas antigas dela

1

COMPARAR · 8 MIN

Faça o mesmo pedido sem exemplo e com três exemplos.

2

SALVAR · 12 MIN

Salve a versão com exemplos como um assistente.

inteli EXEC

AGENDA

9h15	Bloco 1 · de Turing ao modelo de linguagem
9h55	**Bloco 2 · janela e camadas de contexto**
10h35	Break
10h50	Bloco 3 · entendendo os agentes
11h50	Escolha do problema
12h20	Almoço
13h20	Construção em duplas
14h50	Apresentações
15h45	Fechamento

inteli EXEC

PROMPT

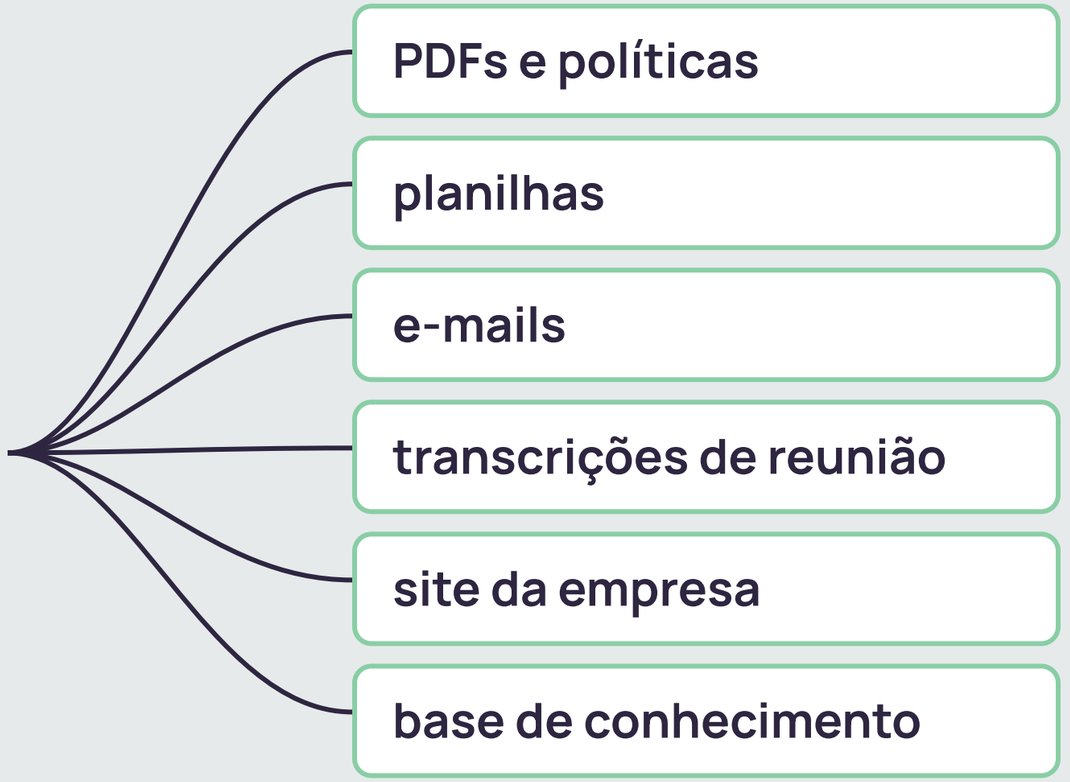
Papel
quem o modelo deve ser

Tarefa
o que fazer

Contexto
o que ele precisa saber

Formato
como entregar

Exemplos
como deve ficar



inteli EXEC

JANELA DE CONTEXTO



2.048
tokens no GPT-3 (2020)

1 milhão
de tokens no Opus 5.5

inteli EXEC

JANELA DE CONTEXTO

PRECEDÊNCIA

MAIS RECENTE

System prompt de quem fez o app

Descrições das skills uma linha de cada

Instruções personalizadas escritas uma vez

CONVERSA

Histórico

Mensagem atual “faça a ata da reunião”

Turno do modelo

`skill: ata` `ferramentas` `resposta`

SKILLS

- Relatório mensal
- **Ata de reunião**
- Proposta comercial

1

INSTRUÇÕES · 10 MIN

Papel, tarefa, formato e o que fazer quando não souber.

2

DOCUMENTOS E AJUSTE · 20 MIN

Anexe os arquivos, faça as perguntas de teste e, se a resposta sair errada, mude a instrução.

inteli EXEC

AGENDA

9h15	Bloco 1 · de Turing ao modelo de linguagem
9h55	Bloco 2 · janela e camadas de contexto
10h35	**Break**
10h50	Bloco 3 · entendendo os agentes
11h50	Escolha do problema
12h20	Almoço
13h20	Construção em duplas
14h50	Apresentações
15h45	Fechamento

inteli EXEC

AGENDA

9h15	Bloco 1 · de Turing ao modelo de linguagem
9h55	Bloco 2 · janela e camadas de contexto
10h35	Break
10h50	**Bloco 3 · entendendo os agentes**
11h50	Escolha do problema
12h20	Almoço
13h20	Construção em duplas
14h50	Apresentações
15h45	Fechamento

arXiv:2210.03629 [cs.CL] 6 Oct 2022

Published as a conference paper at ICLR 2023

REACT: SYNERGIZING REASONING AND ACTING IN LANGUAGE MODELS

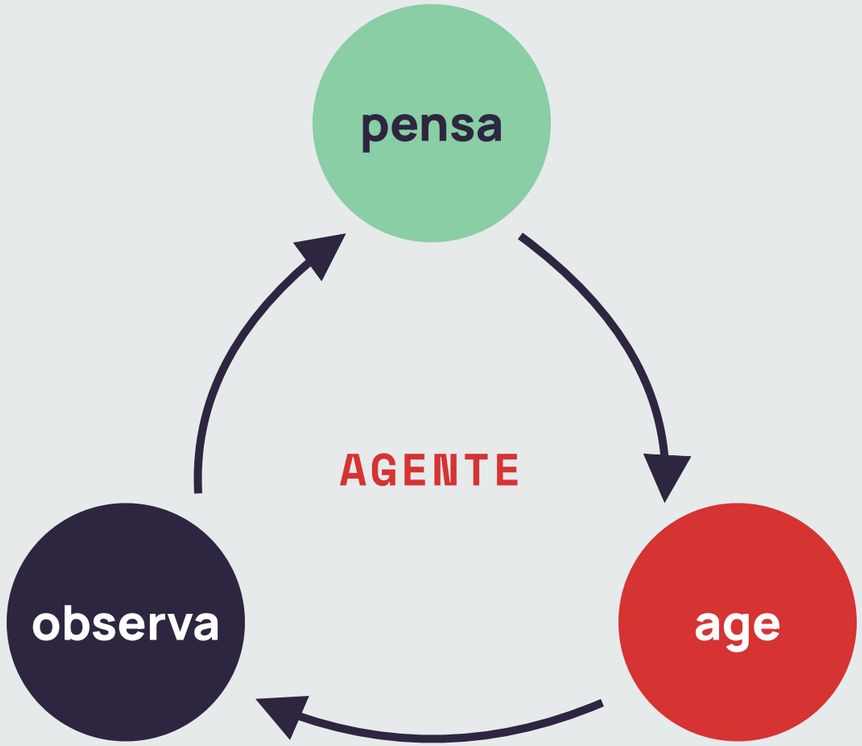
Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, Yuan Cao
Princeton University - Google Research, Brain team

ABSTRACT

While large language models (LLMs) have demonstrated impressive performance across tasks in language understanding and interactive decision making, their abilities for reasoning (e.g. chain-of-thought prompting) and acting (e.g. action plan generation) have primarily been studied as separate topics. In this paper, we explore the use of LLMs to generate both reasoning traces and task-specific actions in an interleaved manner, allowing for greater synergy between the two: reasoning traces help the model induce, track, and update action plans as well as handle exceptions, while actions allow it to interface with and gather additional information from external sources such as knowledge bases or environments. We apply our approach, named ReAct, to a diverse set of language and decision making tasks and demonstrate its effectiveness over state-of-the-art baselines in addition to improved human interpretability and trustworthiness.

inteli EXEC

Quanto custa, em reais, um jantar em Lisboa hoje?

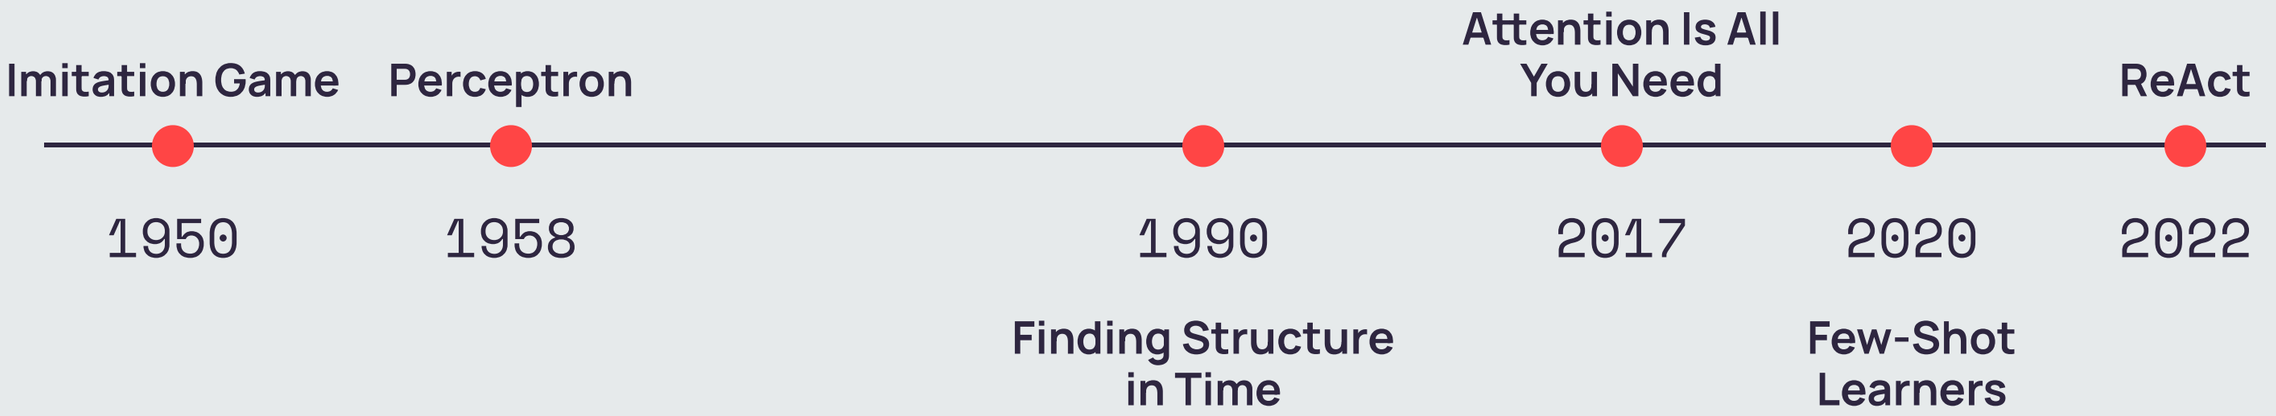


PENSA	Quanto custa um jantar médio lá?
AGE	`buscar("preço médio jantar Lisboa")`
OBSERVA	cerca de €25 por pessoa
PENSA	Agora, a cotação do euro hoje.
AGE	`buscar("cotação euro hoje")`
OBSERVA	€ 1 = R$ 6,10
PENSA	Falta converter.
AGE	`calcular(25 × 6,10)`
OBSERVA	152,50

Cerca de R$ 150 por pessoa.



Composição do diagrama de Jediah Katz · AI Engineer NYC 2026


Imitation Game
1950
Perceptron
1958
Finding Structure in Time
1990
Attention Is All You Need
2017
Few-Shot Learners
2020
ReAct
2022

1

DEFINIR · 15 MIN

Tente lembrar a definição.
Não lembrou? Pergunte ao colega do lado, ou a mim.

AS MESMAS PESSOAS, OUTRO PROBLEMA

- H Helena
- D Diego
- B Beatriz

ARQUITETA AUTÔNOMA

Beatriz

A DOR

“Todo mês monto na mão o relatório de andamento de cada cliente.”

O QUE JÁ EXISTE

planilha de horas do mês

o relatório do mês anterior

HELENA | DIEGO | BEATRIZ

1. Receber a transcrição
2. Separar fatos de opiniões
3. Listar pendências com dono e prazo
4. Marcar o que ficou sem dono
5. **Redigir o e-mail**

ETAPA 5

Redigir o e-mail

QUE CONTEXTO PRECISA?

e-mails anteriores, para o tom

PRECISA DE FERRAMENTA?

não: basta o texto

QUEM CONFERE?

a Helena, antes de enviar

SKILL

1. Receber a transcrição
2. Separar fatos de opiniões
3. Listar pendências
4. Marcar o que não tem dono
5. Redigir o e-mail



fluxo.md

```
nome: acompanhamento-da-reuniao

quando usar: quando chegar uma transcrição.

etapas:
  1. ler a transcrição inteira, com os horários
  2. separar fatos de opiniões
  3. listar pendências com quem e até quando
  4. destacar o que ficou sem dono
  5. redigir o e-mail de acompanhamento

formato da saída: fatos, opiniões, pendências,
o que precisa de decisão, e o e-mail.

o que nunca fazer sozinho:
  - inventar responsável ou prazo
  - escolher entre dois prazos ambíguos
  - enviar o e-mail
```

1

ESCREVER · 10 MIN

Escreva o fluxo nos cinco campos.

2

RODAR · 10 MIN

Peça o trabalho e acompanhe o que ele faz.

3

CONFERIR · 5 MIN

Confira contra os documentos. O que você mudaria?

inteli EXEC

AGENDA

9h15	Bloco 1 · de Turing ao modelo de linguagem
9h55	Bloco 2 · janela e camadas de contexto
10h35	Break
10h50	Bloco 3 · entendendo os agentes
11h50	**Escolha do problema**
12h20	Almoço
13h20	Construção em duplas
14h50	Apresentações
15h45	Fechamento

A DUPLA ESCOLHE O PROBLEMA

1

ESCOLHER · 25 MIN

Cada um conta uma tarefa do próprio trabalho. Escolham uma.

2

REGISTRAR · 5 MIN

Learning Log, página 2: a tarefa, como é feita hoje, o que é dar certo.

inteli EXEC

AGENDA

9h15	Bloco 1 · de Turing ao modelo de linguagem
9h55	Bloco 2 · janela e camadas de contexto
10h35	Break
10h50	Bloco 3 · entendendo os agentes
11h50	Escolha do problema
12h20	**Almoço**
13h20	Construção em duplas
14h50	Apresentações
15h45	Fechamento

inteli EXEC

AGENDA

9h15	Bloco 1 · de Turing ao modelo de linguagem
9h55	Bloco 2 · janela e camadas de contexto
10h35	Break
10h50	Bloco 3 · entendendo os agentes
11h50	Escolha do problema
12h20	Almoço
13h20	**Construção em duplas**
14h50	Apresentações
15h45	Fechamento

CONSTRUÇÃO EM DUPLAS

1

DESTRINCHAR · 20 MIN

A tabela do Learning Log: etapa, contexto, ferramenta, quem confere.

2

CONSTRUIR · 40 MIN

Instruções, documentos e o fluxo. Testem com um exemplo real.

3

PARAR · 10 MIN

14h20: passem para o Learning Log o que mudou no fluxo.

4

AJUSTAR · 20 MIN

Ajustem e preparem a apresentação de 5 minutos.

inteli EXEC

AGENDA

9h15	Bloco 1 · de Turing ao modelo de linguagem
9h55	Bloco 2 · janela e camadas de contexto
10h35	Break
10h50	Bloco 3 · entendendo os agentes
11h50	Escolha do problema
12h20	Almoço
13h20	Construção em duplas
14h50	**Apresentações**
15h45	Fechamento

5 MINUTOS POR DUPLA

1 O PROBLEMA

Qual era o problema?

2 O QUE EXISTE

O que vocês construíram?

3 O QUE FALTA

O que falta para usar de verdade?

inteli EXEC

AGENDA

9h15	Bloco 1 · de Turing ao modelo de linguagem
9h55	Bloco 2 · janela e camadas de contexto
10h35	Break
10h50	Bloco 3 · entendendo os agentes
11h50	Escolha do problema
12h20	Almoço
13h20	Construção em duplas
14h50	Apresentações
15h45	**Fechamento**

1

FECHAR · 15 MIN

Página 4: o que construímos, os próximos passos e o que mudou de ideia.

#Dia 14/11



RESPONDA NOSSA PESQUISA

Leia o QR Code ao lado e nos dê a sua opinião.